

MS671 - Introdução ao Aprendizado de Máquina Profundo

Projeto 01: Reconhecimento de objetos usando YOLO

Gustavo Coimbra de Souza Teixeira - RA 237599

Julia Folgueral - RA 277178

Luiz Fernando de Oliveira Pereira - RA 267356

Maria Eduarda Villéla Silva - RA 212974

Campinas - SP
Maio de 2026

Sumário

1	Introdução	3
2	Metodologia	3
2.1	Ferramentas	3
2.2	A detecção de objetos	3
2.3	Justificativa da escolha do modelo YOLO	4
2.3.1	Vantagens do YOLOv8n sobre o YOLOv3	4
2.4	Análise da Estrutura Algébrica e Representação de Dados do YOLOv8n	4
2.4.1	A Imagem como Estrutura Matricial de Entrada	4
2.4.2	O Fluxo de Transformações Algébricas	5
2.4.3	Representação de Saída e Coordenadas Normalizadas	5
2.5	Métrica de Avaliação Espacial: Intersection over Union (IoU)	6
2.6	Arquitetura e estrutura do YOLO	6
2.6.1	Passos do algoritmo e Motivação	6
2.6.2	Aspectos teóricos e práticos	7
3	Resultados e Discussão	8
3.1	Imagens e Discussão	8
3.2	Hipóteses	16
3.3	Limiares	17
4	Conclusão	17

1 Introdução

O seguinte relatório apresenta a implementação de um sistema de detecção utilizando o YOLOv8n, com ênfase na substituição das funções nativas de pós-processamento por versões manuais desenvolvidas em ambiente Python. O objetivo é analisar o impacto da variação dos limiares de confiança e IoU em diferentes cenários, discutindo como esses hiperparâmetros afetam o equilíbrio entre precisão e não identificação de objetos que deveriam ser identificados, além de comentar a presença de falsos positivos e falsos negativos identificados nas imagens.

2 Metodologia

2.1 Ferramentas

Neste trabalho foram utilizadas ferramentas para implementação da arquitetura em linguagem de programação Python, usando como ambiente de desenvolvimento integrado (IDE) o Google Colab e as seguintes bibliotecas:

- `torch`: usado para construção do modelo;
- `numpy` e `math`: usados para manipulações matemáticas;
- `matplotlib`: usado para visualização;
- `ultralytics`: usado para acessar os pesos do YOLOv8;
- `os`: usado para manipular diretórios e listar arquivos de imagens nas pastas;
- `textwrap`: usado para quebrar automaticamente linhas de texto;
- `requests`: usada para baixar arquivos da internet;
- `PIL` (`Image`, `ImageDraw`, `ImageFont`): usada para carregar as imagens do disco, desenhar as bounding boxes, escrever os nomes das classes e gerenciar as fontes de texto.

2.2 A detecção de objetos

O problema de detecção de objetos é uma evolução natural da classificação de imagens e da localização, visto que lida com a presença de múltiplos objetos em uma mesma cena.

A detecção é fundamental para tecnologias que interagem com o mundo real, permitindo que sistemas computacionais identifiquem e compreendam a disposição espacial de diversos elementos. Alguns exemplos de suas aplicações incluem carros autônomos, reconhecimento facial e diagnóstico médico.

Os principais métodos usados na atualidade são baseados em redes neurais convolucionais (CNNs) e podem ser divididos em diferentes abordagens, apresentadas a seguir:

- **Algoritmo YOLO:** Popular por ser extremamente rápido e processar imagens em tempo real. O YOLO divide a imagem em uma grade e cada célula é responsável por prever a probabilidade de existência de um objeto, as coordenadas da *bounding box* e a classe do objeto.

- **Família R-CNN:** Os métodos R-CNN propõem regiões de interesse com alta probabilidade de conter objetos. A rede executa o classificador apenas sobre essas regiões sugeridas, o que torna o processo mais preciso para certos formatos, porém geralmente mais lento que o YOLO.
- **Janelas deslizantes convolucionais:** Consiste em deslizar uma janela sobre a imagem para classificar cada recorte. Para torná-la viável computacionalmente, as camadas totalmente conectadas da rede são convertidas em camadas convolucionais, permitindo que o algoritmo processe toda a imagem em um único cálculo compartilhado (OverFeat).
- **Segmentação semântica (U-Net):** Usada para classificar cada pixel da imagem. A arquitetura U-Net utiliza convoluções transpostas para reconstruir a resolução da imagem original e fornecer o contorno exato dos objetos.

2.3 Justificativa da escolha do modelo YOLO

Este projeto utiliza o modelo **YOLOv8n** (variante Nano). Diferente do modelo YOLOv3, que pré-define formatos de caixas para associar a cada célula da grade, o YOLOv8n prevê diretamente o centro do objeto em vez de depender de formatos pré-definidos. Isso reduz a complexidade do modelo e melhora a precisão em objetos com proporções variadas e, diferente do YOLOv8, o YOLOv8n é uma versão específica dessa família, onde o sufixo n representa Nano e auxilia na velocidade do processamento.

2.3.1 Vantagens do YOLOv8n sobre o YOLOv3

- **Maior mAP (Mean Average Precision):** O v8 utiliza técnicas modernas de convolução e uma perda (loss) mais refinada, resultando em maior precisão na localização de bounding boxes e pontos.
- **Velocidade superior:** Além de ser mais preciso, o YOLOv8n é muito mais rápido que o YOLOv3, sendo capaz de rodar em hardwares simples com latência mínima.

Portanto, o YOLOv8n representa uma evolução do YOLOv3 focada em máxima eficiência, sendo a escolha melhorada para aplicações de reconhecimento facial por conter uma arquitetura simplificada e desempenho superior em tempo real.

2.4 Análise da Estrutura Algébrica e Representação de Dados do YOLOv8n

A compreensão do modelo YOLOv8n exige a desmistificação do conceito de “visão computacional”. Diferente da percepção biológica, o modelo opera estritamente no domínio da álgebra linear e do cálculo multivariado, tratando a imagem como um tensor multidimensional.

2.4.1 A Imagem como Estrutura Matricial de Entrada

O processo inicia-se com a conversão de uma imagem digital em uma matriz numérica. Para uma entrada padrão de 640×640 pixels em cores (RGB), o dado é estruturado como um tensor $X \in \mathbb{R}^{C \times H \times W}$, onde:

- **C (Canais):** Representa as três camadas de cores (Red, Green, Blue);

- **H (Altura) e W (Largura):** Representam as dimensões espaciais de 640 unidades;
- **Normalização:** Cada elemento $x_{i,j}$ da matriz, originalmente no intervalo $[0, 255]$, é reescalado para o intervalo $[0, 1]$ através da operação matemática $x' = \frac{x}{255}$.

2.4.2 O Fluxo de Transformações Algébricas

O YOLOv8n não “identifica” objetos visualmente; ele aplica uma sequência de convoluções, que matematicamente são produtos escalares entre submatrizes da imagem e tensores de pesos (filtros). A operação fundamental em cada camada pode ser definida pela equação:

$$y = \sigma(W * x + b) \quad (1)$$

Onde W representa a matriz de pesos aprendidos, x é o mapa de características de entrada, b é o vetor de viés (*bias*) e σ representa a função de ativação **SiLU** (*Sigmoid Linear Unit*). O modelo, portanto, é uma sucessão de multiplicações de matrizes que extraem padrões estatísticos dos dados brutos.

2.4.3 Representação de Saída e Coordenadas Normalizadas

Ao final da arquitetura, o modelo gera um tensor de predição. É fundamental destacar que o YOLOv8n não gera uma imagem, mas sim uma matriz densa de dados. Como o modelo é *anchor-free*, isto é, ao invés de ajustar uma caixa pré-existente, o modelo prevê a distância do centro de um objeto até as suas quatro bordas diretamente, predizendo o centro e o tamanho do objeto.

Para garantir a invariância de escala, o modelo não trabalha com unidades de pixels absolutos, mas com **coordenadas normalizadas** no intervalo $[0, 1]$. A saída para cada detecção é composta pelo vetor:

$$P_{out} = [x_{center}, y_{center}, w, h, c_1, c_2, \dots, c_n] \quad (2)$$

- x_{center}, y_{center} : Localização do centro do objeto relativa aos limites da imagem;
- w, h : Largura e altura proporcionais às dimensões totais;
- c_n : Probabilidades logísticas para cada classe de objeto.

Para garantir que esses valores de regressão permaneçam confinados entre 0 e 1, o modelo aplica a função logística **Sigmoide** nos neurônios de saída:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (3)$$

Dessa forma, a “visão” do modelo é, em última análise, a resolução de um problema de otimização numérica onde a matriz final de números reais é decodificada em coordenadas retangulares sobre a interface visual.

2.5 Métrica de Avaliação Espacial: Intersection over Union (IoU)

Para que o modelo valide a precisão das coordenadas normalizadas previstas, utiliza-se a métrica algébrica *Intersection over Union* (IoU). O IoU quantifica a sobreposição entre a caixa delimitadora predita (B_p) e a caixa fundamental de referência (*Ground Truth*, B_g).

Matematicamente, o IoU é definido pela razão entre a área da interseção e a área da união das duas regiões:

$$IoU = \frac{\text{Área}(B_p \cap B_g)}{\text{Área}(B_p \cup B_g)} \quad (4)$$

A interpretação desta fórmula no domínio matricial segue os seguintes critérios:

- **Interseção** ($B_p \cap B_g$): Representa a área onde a predição e o alvo coincidem. Se não houver sobreposição, o valor é 0.
- **União** ($B_p \cup B_g$): Representa a área total coberta por ambas as caixas, calculada como $\text{Área}(B_p) + \text{Área}(B_g) - \text{Área}(B_p \cap B_g)$.
- **Intervalo**: O resultado é um escalar $\in [0, 1]$, onde 1 indica uma sobreposição perfeita e 0 indica total divergência espacial.

No YOLOv8n, o cálculo do IoU é fundamental para o algoritmo de *Non-Maximum Suppression* (NMS). Como o modelo gera milhares de matrizes de predição para uma única imagem, o NMS utiliza o IoU para comparar predições redundantes que possuem alta sobreposição e manter apenas aquela com o maior escore de confiança, descartando as demais através de um limiar algébrico pré-definido.

2.6 Arquitetura e estrutura do YOLO

O YOLO divide a imagem de entrada em uma grade, na qual cada célula é responsável por prever um vetor de saída y que contém os seguintes componentes:

- p_c : probabilidade de existir um objeto na célula.
- b_x, b_y, b_h, b_w : parâmetros da *bounding box* (coordenadas do ponto médio, altura e largura).
- c_1, c_2, c_3 : probabilidades das classes específicas (ex.: cachorro, pessoa, bicicleta).

Para permitir que uma mesma célula detecte múltiplos objetos, utilizam-se *anchor boxes* (formas de bounding boxes pré-definidas que permitem às redes neurais detectar múltiplos objetos em uma mesma célula da grade). Nesse caso, o vetor de saída de cada célula é expandido para incluir as predições de cada âncora.

2.6.1 Passos do algoritmo e Motivação

- **Atribuição no treinamento**: Cada objeto do conjunto de treinamento é associado exclusivamente à célula da grade que contém o seu ponto médio. Embora um objeto ocupe várias células, apenas uma é responsável por ele, evitando duplicações no rótulo alvo. Se houver *anchor boxes*, o objeto é atribuído àquela com maior **IoU (Intersection over Union)** com a caixa real, permitindo que diferentes unidades da rede se especializem em formatos de objetos específicos.

- **Predição convolucional única:** A rede neural processa a imagem e gera todo o volume de predições de uma só vez. A intuição é aproveitar o cálculo compartilhado entre as células da grade, tornando o processo muito mais eficiente do que executar uma ConvNet centenas de vezes sobre janelas deslizantes.
- **Non-Max Suppression (NMS):** Na prática, várias células próximas podem prever o mesmo objeto com alta probabilidade. O NMS elimina essas detecções redundantes seguindo dois critérios: primeiro, descarta predições com baixa confiança; depois, seleciona a caixa de maior probabilidade e remove todas as outras com sobreposição significativa (alto IoU) com ela.

2.6.2 Aspectos teóricos e práticos

- **Aspectos teóricos:** As coordenadas b_x e b_y são sempre codificadas entre 0 e 1 (relativas à célula), enquanto a altura (b_h) e largura (b_w) são expressas como frações da dimensão da célula, podendo ser maiores que 1 se o objeto cruzar fronteiras. A *loss function* geralmente utiliza o erro quadrático médio para as coordenadas da caixa e pode usar *log-likelihood* para as classificações de categoria.
- **Aspectos práticos:** A métrica IoU é fundamental para avaliar se uma detecção é correta. O YOLO é amplamente aplicado em tecnologias que exigem resposta imediata, no exemplo de carros autônomos, como já mencionado anteriormente, onde é crucial detectar simultaneamente pedestres, outros veículos e sinalizações em tempo real.


3 Resultados e Discussão

Nesta seção, são apresentadas análises sobre o funcionamento do modelo em 4 imagens selecionadas do repositório, com o objetivo de ilustrar o funcionamento do algoritmo e as interpretações gerais. Em primeiro plano, são apresentadas as imagens com suas respectivas tabelas e um gráfico, mostrando a quantidade de detecções considerando os limiares 0,05, 0,15, 0,25, 0,35, 0,45, 0,55, 0,65 e 0,75 para cada uma das quatro figuras. Em seguida, realiza-se uma discussão sobre as figuras e sobre as diferenças de reconhecimento para cada imagem analisada. Por fim, comentam-se as hipóteses referentes às análises, a utilização de cada um dos limiares e possíveis melhorias que poderiam ser implementadas.


3.1 Imagens e Discussão

Efeito dos Limiares de Confiança e IoU


Confiança baixa, IoU baixo - Confiança = 0.10 e IoU = 0.30 (12 detecções)



Configuração padrão YOLOv8 - Confiança = 0.25 e IoU = 0.45 (9 detecções)



Confiança alta, IoU alto - Confiança = 0.50 e IoU = 0.60 (9 detecções)



Confiança muito alta - Confiança = 0.70 e IoU = 0.45 (6 detecções)




Figura 1: Análise de amigos no IMECC para diferentes limiares de Confiança e IoU.

Tabela 1: Comparação do desempenho da detecção sob diferentes limiares da imagem de amigos no IMECC.

Imagem	Confiança	IoU (NMS)	Detecções
Cenário 1	0.10	0.30	12
Cenário 2	0.25	0.45	09
Cenário 3	0.50	0.60	09
Cenário 4	0.70	0.45	06




Figura 2: Análise de limiares (Amigos no IMECC).

A análise da Tabela 1 e da Figura 1, contendo um grupo de pessoas, revela alguns desafios da detecção de objetos devido à sobreposição de pessoas e à identificação de objetos inexistentes em certos cenários. No cenário com confiança 0,10 e IoU 0,30, observa-se um excesso de predições: o modelo gera múltiplas caixas para a mesma pessoa ou identifica elementos inexistentes ao fundo, consequência direta do baixo limiar de confiança. Por outro lado, ao elevar a confiança para 0,70, pessoas parcialmente sobrepostas ou com rostos encobertos deixam de ser detectadas, demonstrando que um limiar excessivamente alto prejudica a capacidade do modelo de encontrar todos os objetos da cena. Na configuração padrão (confiança 0,25 / IoU 0,45), o algoritmo de Supressão Não-Maximal (NMS) implementado consegue isolar com sucesso a maioria dos indivíduos, sem falsos positivos nem falsos negativos relevantes.

Pela Figura 2, observa-se queda acentuada de 15 detecções (score = 0,05) para 9 (score = 0,25, valor padrão), estabilizando-se nesse patamar até score 0,45, com nova queda progressiva até 6 detecções em score = 0,75. O comportamento sugere que parte das pessoas é detectada com confiança intermediária, sendo eliminada conforme o limiar aumenta. Quanto ao efeito do IoU, o número de detecções sobe de 6 (IoU = 0,1) para 11 (IoU = 0,9), com crescimento mais acentuado a partir de IoU 0,7. Isso indica que caixas bastante sobrepostas são geradas para alguns indivíduos, sendo suprimidas apenas quando o limiar é mais estrito.

Efeito dos Limiares de Confiança e IoU


Confiança baixa, IoU baixo - Confiança = 0.10 e IoU = 0.30 (42 detecções)



Configuração padrão YOLOv8 - Confiança = 0.25 e IoU = 0.45 (27 detecções)



Confiança alta, IoU alto - Confiança = 0.50 e IoU = 0.60 (15 detecções)



Confiança muito alta - Confiança = 0.70 e IoU = 0.45 (3 detecções)



Figura 3: Análise da imagem Avenida Paulista para diferentes limiares de Confiança e IoU

Tabela 2: Comparação do desempenho da detecção sob diferentes limiares da imagem Avenida Paulista.

Imagem	Confiança	IoU (NMS)	Detecções
Cenário 1	0.10	0.30	42
Cenário 2	0.25	0.45	27
Cenário 3	0.50	0.60	15
Cenário 4	0.70	0.45	03





Figura 4: Análise de limiares (Avenida Paulista).

A avaliação da cena urbana na Avenida Paulista, Figura 3, juntamente com a Tabela 2, evidencia a complexidade da detecção em ambientes com múltiplos objetos de tamanhos variados e com grande sobreposição. No cenário de confiança 0,10 e IoU 0,30, o modelo atinge o maior número de detecções (42), identificando pedestres em planos muito distantes. No entanto, essa sensibilidade extrema introduz falsos positivos significativos: com o limiar de IoU baixo, ocorrem detecções duplicadas para uma mesma pessoa. Em contraste, a configuração de confiança 0,70 reduz o resultado para apenas 3 detecções, ignorando quase toda a multidão e mantendo apenas os objetos com maior nitidez e proximidade da câmera. A configuração padrão, com 27 detecções, ainda deixa muitos pedestres ao fundo sem detecção. Para fins de monitoramento de pedestres em uma avenida, limiares de confiança menores seriam mais adequados. Esta imagem exemplifica a importância do limiar de IoU em cenas densas, visto que um valor muito alto permitiria o empilhamento de caixas em pedestres próximos.


Pela Figura 4, nota-se uma queda de aproximadamente 58 para 26 detecções no valor padrão de confiança. A cena urbana com pedestres, veículos e elementos de fachada gera naturalmente muitos candidatos de baixa confiança, que são progressivamente eliminados com o aumento do limiar. Quanto ao efeito do IoU, esta cena apresenta o maior crescimento, passando de aproximadamente 23 detecções (IoU = 0,1) para aproximadamente 48 (IoU = 0,9). O salto ocorre principalmente entre IoU = 0,8 e 0,9, sugerindo que as detecções redundantes em cenas urbanas complexas possuem sobreposição muito elevada, sendo suprimidas apenas com um NMS mais estrito.

Efeito dos Limiares de Confiança e IoU

Confiança baixa, IoU baixo - Confiança = 0.10 e IoU = 0.30 (41 detecções)



Configuração padrão YOLOv8 - Confiança = 0.25 e IoU = 0.45 (20 detecções)



Confiança alta, IoU alto - Confiança = 0.50 e IoU = 0.60 (10 detecções)



Confiança muito alta - Confiança = 0.70 e IoU = 0.45 (4 detecções)



Figura 5: Análise da imagem food para diferentes limiares de Confiança e IoU.

Tabela 3: Comparação do desempenho da detecção sob diferentes limiares da imagem food.

Imagem	Confiança	IoU (NMS)	Detecções
Cenário 1	0.10	0.30	41
Cenário 2	0.25	0.45	20
Cenário 3	0.50	0.60	10
Cenário 4	0.70	0.45	04




Figura 6: Análise de limiares (food).


A imagem de uma mesa com comida, Figura 5, ilustra a dificuldade de detecção em cenários com alta variação de texturas e a diferença da quantidade de detecções é evidenciado pela Tabela 3. Por exemplo, a cenoura pode estar cortada de diferentes maneiras. No cenário com confiança 0,10 e IoU 0,30, o modelo exibe falsos positivos (41 detecções): certas porções de alimento são classificadas como *bowl* (tigelas) e um *refrigerator* inexistente é detectado. Além disso, o modelo tenta classificar elementos minúsculos dentro das travessas, resultando em sobreposição excessiva de *bounding boxes*.

Ao aumentar os limiares, observa-se a importância do NMS para lidar com a diversidade visual dos alimentos. Na configuração padrão (20 detecções), o sistema distingue melhor os pratos, embora ainda haja falsos positivos pontuais, como a torta classificada como *bowl*. Na configuração de confiança 0,70, apenas 4 objetos são selecionados, evidenciando que itens mais afastados da câmera perdem a ativação necessária para serem detectados. Este cenário confirma que, para aplicações de reconhecimento de alimentos com alta variação de textura, o equilíbrio entre confiança e IoU é determinante para evitar que o modelo foque em detalhes irrelevantes.


Analisando a Figura 6, observa-se que a cena apresenta o maior número de detecções em pontuações baixas (aproximadamente 58 em score = 0,05), caindo abruptamente para aproximadamente 20 no valor padrão e chegando a apenas 2 em score = 0,75. A grande variação reflete a complexidade da cena, com múltiplos alimentos e objetos sobrepostos detectados com confiança variada. Quanto ao IoU, partindo de 15 detecções (IoU = 0,1), o número cresce de forma suave até aproximadamente 20 em IoU = 0,45 (padrão), com salto expressivo para 37 em IoU = 0,9. O aumento drástico nos valores altos de IoU evidencia que o modelo gera múltiplos candidatos sobrepostos para os mesmos itens alimentares, que normalmente seriam suprimidos.

Efeito dos Limiares de Confiança e IoU


Confiança baixa, IoU baixo - Confiança = 0.10 e IoU = 0.30 (1 detecção)



Confiança alta, IoU alto - Confiança = 0.50 e IoU = 0.60 (1 detecção)



Configuração padrão YOLOv8 - Confiança = 0.25 e IoU = 0.45 (1 detecção)



Confiança muito alta - Confiança = 0.70 e IoU = 0.45 (1 detecção)




Figura 7: Análise da imagem cat para diferentes limiares de Confiança e IoU.

Tabela 4: Comparação do desempenho da detecção sob diferentes limiares da imagem cat.

Imagem	Confiança	IoU (NMS)	Detecções
Cenário 1	0.10	0.30	01
Cenário 2	0.25	0.45	01
Cenário 3	0.50	0.60	01
Cenário 4	0.70	0.45	01




Figura 8: Análise de limiares (cat).

Diferentemente dos cenários anteriores, a imagem do gato isolado, Figura 7, apresenta total estabilidade em todas as variações de limiares testadas, que é ressaltado na Tabela 4. Isso se deve a fatores como a alta nitidez do objeto, o forte contraste entre o animal e o plano de fundo e a ausência de sobreposições ou outros objetos na cena. Essas são as condições ideais para o modelo, pois eliminam a possibilidade de falsos positivos e falsos negativos. Mesmo no limiar de confiança 0,70, a detecção persiste inalterada, indicando que a rede neural atingiu nível máximo de ativação para as características do gato. Além disso, a presença de apenas uma detecção em todos os cenários confirma que o NMS manual não suprime objetos erroneamente quando não há competição por sobreposição. Este exemplo serve como validação do modelo, visto que as oscilações observadas nas imagens anteriores são causadas pela ambiguidade dos cenários e não por instabilidades no código de detecção implementado.

O gráfico de limiares de confiança versus número de detecções mostra uma curva completamente plana em 1 detecção ao longo de todo o intervalo avaliado (0,05 a 0,75). Isso indica que o modelo atribui altíssima confiança ao único objeto presente, tornando o resultado insensível à variação desse parâmetro nessa faixa. De forma análoga, a curva permanece constante em 1 detecção para todo o intervalo de IoU (0,1 a 0,9), confirmando a robustez da detecção na ausência de candidatos concorrentes.

3.2 Hipóteses

Os resultados obtidos permitem formular e discutir algumas hipóteses sobre o comportamento do modelo YOLOv8 nas diferentes cenas analisadas.

O ruído visual da cena amplifica a sensibilidade aos limiares. Cenas com muitos elementos, texturas variadas e sobreposições tendem a tornar o modelo muito mais sensível a variações nos parâmetros de confiança e IoU. Isso foi observado claramente na imagem de alimentos (Figura 5), onde pequenas alterações nos limiares produziram grandes variações no número de detecções. Em contraste, a imagem do gato (Figura 7), com objeto único, nítido e bem contrastado, permaneceu completamente estável ao longo de todo o intervalo testado. Essa diferença sugere que o ruído visual da cena aumenta a incerteza do modelo, ou seja, quanto mais ambígua a entrada, maior o impacto de qualquer ajuste nos hiperparâmetros.

A densidade de objetos afeta de forma assimétrica a confiança e o IoU. Nas cenas com alta densidade de elementos, como a Avenida Paulista (Figura 3), observou-se que o limiar de IoU tem impacto proporcionalmente maior do que em cenas com objetos dispersos. Isso indica que, em ambientes densos, o principal problema não é a confiança do modelo em cada detecção individual, mas sim a capacidade do NMS de separar objetos próximos sem suprimir detecções legítimas. Cenas dispersas, por sua vez, são mais sensíveis ao limiar de confiança, pois há poucos candidatos concorrentes e a principal fonte de erro são os falsos positivos de baixa probabilidade.

O modelo tende a ter mais dificuldade com categorias de objetos visualmente heterogêneas. Na cena de alimentos (Figura 5), itens da mesma categoria, como travessas e tigelas, apresentaram grande variação de forma, cor e textura, levando o modelo a classificá-los incorretamente ou a gerar múltiplas detecções sobrepostas para o mesmo objeto. Em contraste, categorias visualmente homogêneas, como pessoas em pé vistas de frente, foram detectadas com maior consistência na imagem do grupo de amigos no IMECC (Figura 1). Isso sugere que a heterogeneidade visual intraclasse é um fator relevante na performance do modelo, independentemente dos limiares adotados.

3.3 Limiares

A análise dos resultados permitiu identificar a sensibilidade do modelo YOLOv8 aos limiares de Confiança e de Intersecção sobre a União. O limiar de confiança atua como um filtro de entrada. Valores excessivamente baixos (como 0,10) permitem que o modelo apresente detecções de baixa probabilidade, resultando em falsos positivos provenientes de ruídos ou texturas do cenário que guardam semelhança com os objetos que deveriam ser detectados.

Por outro lado, o limiar de IoU controla a “agressividade” da Non-Max Suppression (NMS) implementada. Durante os testes, observou-se que um IoU elevado (acima de 0,60) torna o filtro abrangente demais, mantendo múltiplas *bounding boxes* para um único objeto e prejudicando a precisão. Já um IoU baixo (abaixo de 0,30) torna o sistema rígido demais, podendo descartar objetos reais parcialmente tampados ou muito próximos entre si, como observado em imagens com alta quantidade de elementos. Para manter o equilíbrio, a configuração padrão de limiares (0,25 para confiança e 0,45 para IoU) oferece a melhor precisão para a base de dados testada.

Apesar do desempenho satisfatório da arquitetura YOLOv8 com os pesos pré-treinados no dataset COCO, algumas melhorias poderiam ser implementadas para elevar a robustez e a qualidade do sistema:

- **Fine-tuning em domínio específico:** O modelo utiliza pesos generalizados. O ajuste fino (*fine-tuning*) com imagens específicas do domínio de interesse permitiria que as camadas da cabeça de detecção se especializassem nas texturas e iluminações particulares desse conjunto de dados.
- **Soft-NMS:** Uma possível melhoria seria substituir o NMS tradicional implementado pelo Soft-NMS. Em vez de excluir caixas com IoU elevado, o Soft-NMS reduz de forma contínua a confiança das caixas sobrepostas, melhorando a detecção em cenários com objetos muito próximos.
- **Aumento de dados dinâmico (*Data Augmentation*):** A implementação de técnicas como *Mosaic Augmentation* e *MixUp* durante o treinamento auxiliaria o modelo a lidar melhor com variações de escala e identificação de objetos parcialmente tampados. Essa abordagem seria interessante, pois resolveria os pontos de dificuldade identificados nos resultados atuais.

4 Conclusão

Este trabalho apresentou a implementação de um sistema de detecção de objetos baseado no YOLOv8, com foco na análise do comportamento do modelo sob diferentes configurações dos limiares de confiança e IoU. A partir de análises em quatro imagens com características distintas, foi possível observar que o desempenho do modelo é fortemente influenciado pela complexidade visual de cada cena.

Cenas simples, como a imagem do gato isolado, demonstraram que o modelo é capaz de realizar detecções estáveis e corretas independentemente dos limiares utilizados. Por outro lado, cenas complexas e com muita pluralidade, como a da Avenida Paulista (Figura 3) e da mesa de comida (Figura 5), evidenciaram a necessidade de um ajuste cuidadoso dos parâmetros. Limiares muito permissivos geram falsos positivos, enquanto limiares muito restritivos suprimem detecções verdadeiras.

A configuração padrão (confiança 0,25 e IoU 0,45) mostrou-se um bom ponto de equilíbrio geral, embora cenários específicos demandem ajustes particulares. As melhorias propostas, como *fine-tuning*, Soft-NMS e técnicas de aumento de dados , representam caminhos possíveis para aumentar a robustez do sistema em aplicações reais.

Referências

- [1] PRINCE, Simon J. D. *Understanding Deep Learning*. MIT Press, 2023. Disponível em: <https://udlbook.github.io/udlbook/>.
- [2] REDMON, Joseph; DIVVALA, Santosh; GIRSHICK, Ross; FARHADI, Ali. You Only Look Once: Unified, Real-Time Object Detection. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [3] GIRSHICK, Ross; DONAHUE, Jeff; DARRELL, Trevor; MALIK, Jitendra. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2014.
- [4] REN, Shaoqing; HE, Kaiming; GIRSHICK, Ross; SUN, Jian. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. In: *Advances in Neural Information Processing Systems (NeurIPS)*, 2015.
- [5] FLORINDO, João. *Semana 12 - Detecção de Objetos*. Universidade Estadual de Campinas, material de aula, 2026.